

# Práctica 1

# Definición

- Un etiquetador/anotador recibe una secuencia de palabras y le asigna una secuencia de etiquetas gramaticales (tags)

El niño come una manzana



ETIQUETADOR



DET N V DET N

# Dificultad de la anotación: Ambigüedad

- Una misma palabra puede tener etiquetas diferentes en diferentes frases.
  - Ha pesado/V tres kilos
  - El profesor es un pesado/N
  - Un discurso pesado/ADJ
- La categoría gramatical de una palabra en una frase depende del contexto de utilización.
  - Ejemplo.
    - La palabra “médico” después del determinante (“un”) generalmente actuará como nombre (y no como adjetivo). “Un medico/N” vs. “un equipo médico/ADJ”

# ¿Cómo automatizar el proceso?

- Opción 1:
  - Obtener un diccionario
  - Escribir reglas
    - **si**  $w_i$  = “médico” y  $t_{i-1}$  es un DET entonces
    - **entonces**  $t_i = N$
- Opción 2: Utilizando Aprendizaje Automático (Machine Learning)


# Tagging como *Supervised Machine Learning*

Corpus

- Datos anotados manualmente: “Training test”. En LC se suele llamar a estos datos un “Corpus anotado”.
- Objetivo: extraer de estos datos “**conocimiento**” para poder repetir la operación de etiquetado con otros textos

# Tagging como *Supervised Machine Learning*


## 1 - Entrenamiento



- El Modelo del Lenguaje (ML) puede consistir en reglas, conjunto de probabilidades, pesos de un red neuronal, etc.

# Tagging como *Supervised Machine Learning*


## 2 – Etiquetado



- Utilizando el ML se puede ahora etiquetar cualquier texto nuevo

# Tagging como *Supervised Machine Learning*

## 3 – Evaluación



- Para conocer la precisión del algoritmo de etiquetado se compara con un texto anotado manualmente que no se ha usado para el entrenamiento

# Anotación Estadística

- Dada una secuencia de palabras  $\mathbf{W}=(w_1, \dots, w_n)$  y una secuencia de tags  $\mathbf{T}=(t_1, \dots, t_n)$  definimos la probabilidad de que a  $\mathbf{W}$  le corresponda  $\mathbf{T}$  como:

$$P(T|W)$$

- Consideramos que la mejor secuencia será la maximize la eq. anterior

$$\hat{T} = \operatorname{argmax}_T P(T|W)$$

# Anotación Estadística

- La realidad (aplicando la regla de la cadena)

$$P(T|W) = \prod_{i=1}^N P(t_i|w_N, \dots, w_1, t_{i-1}, \dots, t_1)$$

- Lo que haremos en la práctica 1

$$P(T|W) \approx \prod_{i=1}^N P(t_i|w_i)$$

# ¿Cómo podemos utilizar el corpus?

- Podemos extraer  $P(t_i|w_i)$  aplicando la regla general

$$P(A|B) = \frac{P(A \wedge B)}{P(B)}$$

$P(A \wedge B)$  o  $P(B)$  las podemos estimar a partir de las ocurrencias en el corpus.

- Ejemplo:

$$P(t_i|w_i) = \frac{\text{count}(t_i, w_i)}{\text{count}(w_i)}$$

- numerador: veces que la palabra  $w_i$  aparece etiquetada como  $t_i$
- denominador: veces que aparece la palabra  $w_i$